第2章
因子投资方法论

本章介绍学术界在进行实证资产定价研究时最常用的方法。熟悉并掌握它们有两个作用。首先，在金融学、经济学、会计学的顶级期刊，以及投资业界的最高水平期刊上，大量关于实证资产定价和因子投资的文章均会使用这些方法[1]。掌握它们有助于读懂最新的论文，获得研究因子的新思路。其次，很多方法（例如投资组合排序法和Fama–MacBeth回归）在业界的因子研究中得到了广泛的应用。

本章内容共分为8节，把因子投资方法论中的各知识点按照严谨的先后顺序有机地串联在一起。为了帮助读者更好地学习本章内容，以下首先简要说明本章的结构，每节的开头则会进一步解释上下文的关联。本章的2.1节首先介绍如何使用排序法构建因子模拟组合并进行检验，它是一切的基础。无论是研究多因子模型还是异象，都需要用到它。接下来的2.2节是本章的核心，说明如何使用不同的回归方法对多因子模型进行检验。2.3节将进一步对因子暴露和因子收益率检验进行解读。因子投资中的一个重要内容是通过异象获取多因子模型无法解释的超额收益，本章的2.4节就来讨论这个问题。2.5节解读比较不同多因子模型的方法，它一直是学术界研究的热点。本章的2.6和2.7两节内容相对独立。2.6节说明因子正交化的重要性。在业界进行因子投资时，因子正交化是十分常见的处理方式。2.7节介绍广义矩估计。掌握这个非常强大的计量经济学工具将为今后持续展开因子投研工作打下坚实的基础。最后，2.8节对全章内容进行总结，给出因子投资中使用这些方法的建议。

在正式介绍不同的方法之前，先来说说本章的写作风格。本章的内容将不可避免地涉及大量的数学公式。然而，本书的目标并不是成为纯理论的“数学”书，因此行文不会变成定理或者证明的罗列。美国金融协会前主席、实证资产定价领域的顶尖学者John Cochrane教授曾说“在现实和学术中，金融中的数学其实并不难。难的是理解如何使用这些方程，以及它们对这个世界的真正意义。”[2]本书作者十分认可上述观点，因此本书在介绍数学公式和推导时会遵循以下两个目标：（1）尽量阐述数学背后的直观含义，帮助读者理解公式所传递的内容；（2）把公式的表达和推演的逻辑说清楚，帮助读者在实际因子研究中应用这些方法。对于第一点，行文中会加入必要的图示，通过可视化解释公式的含义；对于第二点，行文中会抠一些看似不那么重要的细节，比如矩阵和向量的阶数。希望本章

的内容既能够让读者暂时跳出细节，直观上理解公式的全貌，又能为读者提供足够的细节，从而在研究和实践因子投资中运用它们。本着这两个目标，文中涉及的数学会力争严谨，但也会做到“点到为止”。对某个方法感兴趣的读者，可以进一步学习相关章节给出的参考文献。

[1]金融学领域公认的三大顶级期刊为*Journal of Finance*、*Journal of Financial Economics*以及*Review of Financial Studies*；经济学领域的顶级期刊包括*American Economic Review*、*Journal of Economic Perspectives*、*Journal of Political Economy*以及*The Quarterly Journal of Economics*等；会计学领域的顶级期刊包括*Journal of Accounting and Economics*、*Journal of Accounting Research*以及*The Accounting Review*等；投资业界的代表性期刊则要数*The Journal of Portfolio Management*。

[2]Cochrane教授的原话是*“The math in real, academic, finance is not actually that hard.Understanding how to use the equations, and see what they really mean about the world…that’s hard.”*。

WPS PDF编辑试用

2.1 投资组合排序法

由1.1.2节因子的定义可知，一个因子代表了不同资产收益率的某种驱动力，而该因子的收益率就是这些资产的共性收益。然而在上述定义中，因子是十分抽象的。因子收益率是什么呢？它又如何计算呢？举例来说，股票市场的整体估值水平和股票的收益率密切相关，估值的高低能够影响股票收益率的共同涨跌。又比如，股票市场作为经济的晴雨表，股票收益率的高低又都受到宏观经济好坏（如GDP的高低）的影响。这些例子说明，像估值、GDP这些都可以作为因子来解释股票的收益率，但是如何定量计算它们的收益率呢？为了回答问题，就要用到实证资产定价和因子投资中的一个非常重要的概念——因子模拟投资组合（factor mimicking portfolio）。如果说因子是抽象的，那么因子模拟投资组合就是这个抽象概念的实际载体，它是定量研究和使用因子的出发点。

2.1.1 因子模拟投资组合

因子模拟投资组合是使用股票资产、围绕某目标因子构建的投资组合；该投资组合需满足以下两个条件：

- 条件一：该投资组合仅在目标因子上有大于零的暴露、在其他因子上的暴露为零；
- 条件二：在所有满足条件一的投资组合中，该投资组合的特质性风险（idiosyncratic risk）最小。

以下通过一个假想的例子逐条解读这两个条件。假设有两个因子A和B以及四支股票。表2.1给出了这些股票在这两个因子上的暴露以及它们的特质性风险。接下来按上述两个条件来构建因子A的因子模拟组合。

首先来看一个错误的做法，即按同等资金权重配置股票一和股票二。它们在因子A上的因子暴露都很高，似乎能够反映出因子A的收益率。然而，这种做法之所以错误，是因为这两支股票在因子B上的因子暴露也非常高。因此，由它们二者构成的投资组合的收益率将受到因子A和B的共同影响。这个问题就体现出满足上述定义中第一个条件的重要性：因子模拟投资组合的收益率应该仅由目标因子驱动，而不受其他因子的影响（意味着投资组合对于其他因子的因子暴露为零），这才能纯粹反映出该目标因子的收益。按照这个条件，可以选择按同等资金权重配置股票一和股票三。由于它们在因子B上的暴露取值相反，因此这二者构成的投资组合仅在因子A上有暴露，满足第一个条件。

WPS PDF编辑试用

表2.1　股票和因子暴露及特异风险示意

股票	因子 A 暴露	因子 B 暴露	特质性风险
股票一	0.8	0.4	1%
股票二	1.3	0.6	2%
股票三	0.6	−0.4	5%
股票四	1.2	−0.4	1%

上面第一条虽然很关键，但是在它的限制下，得到的投资组合并不一定是唯一的。比如同等权重配置股票一和股票三满足第一个条件；类似的，同等权重配置股票一和股票四也满足第一个条件。那么，它们是否都可以作为因子A的因子模拟组合？还是需要进一步取舍呢？这时就要给出第二个条件——因子模拟投资组合的特质性风险最小。该组合的特质性风险由构成它的个股的特质性风险决定。对于多因子模型来说，个股的特质性风险源自个股收益率在时序上的随机扰动，即式（1.5）中的ε_t。对于一个满足条件一的投资组合，它的收益率由两部分驱动，分别为目标因子和构成该组合的个股的特质性风险。

如果该组合中特质性风险很高，那么特质性风险的影响就会压过目标因子而占主导地位，这会给因子收益率的计算带来较大的误差。换句话说，只有尽可能地排除特质性风险的影响、使得该投资组合的收益中的绝大部分都由目标因子驱动，才能够准确地计算因子的收益率。这正是第二个条件背后的动机。因子模拟投资组合是所有满足条件一的投资组合中，特质性风险最低的。回到上面的例子，在股票一和股票三、股票一和股票四这两个组合中，由表中数据可知，后者的特质性风险要低于前者，因而满足条件二。因此，根据因子模拟组合需满足的两个条件，最终可通过等权重配置股票一和股票四构建了因子A的因子模拟投资组合。

有了因子模拟投资组合，就可以计算因子收益率了。从定义出发，因子模拟投资组合就是针对某目标因子构建的投资组合；在条件一和条件二的约束下，该投资组合的收益率应尽可能地仅由目标因子驱动，因此该投资组合的收益率就是因子收益率。从上面的例子也不难看出，为了构建因子模拟组合，首先需要知道资产在不同因子上的暴露。在因子暴露已知的前提下，人们可以通过不同的方法来构建因子模拟投资组合。在众多方法中，有一个简化的方法在学术界的实证资产定价研究和业界的因子投资中均得到了广泛的应用，它就是投资组合排序法（portfolio sort），简称排序法。

2.1.2　排序法及其检验

大量研究发现，股票的收益率受很多因子的影响。因性质不同，因子又可以被分为不同的种类。以2.1节开篇举的两个例子来说，围绕诸如估值这类股票的财务信息或者量价数据构建的因子代表了最主流的一类因子，它们被称为股票的风格因子（style factor），典型的风格因子还包括市值、盈利、低波动等；而像围绕GDP这类经济数据构建的因子则被称为宏观经济因子。因子的种类远不止风格因子和宏观经济因子两类，上面的例子只是为了说明数据的属性决定了因子的类别。有必要指出的是，本节介绍的排序法是针对风格因子构建因子模拟投资组合

的一种简化方法。对于其他类型因子，比如宏观经济因子，该方法并不适用（2.2节会说明如何处理其他类型的因子）。话虽如此，由于风格因子在股票多因子模型中的地位无人能及，这种方法得到了广泛的使用。

前文2.1.1节的例子说明，构建因子模拟组合的前提是知道所有股票在该因子上的暴露。由式（1.3）可知，股票在某因子i上的暴露β_i反映的是在控制了其他因子后，该目标因子的收益率变化对股票超额收益变化的影响程度。这意味着首先需要知道因子收益率才能计算因子暴露。而从前文可知，首先需要有因子模拟组合才能计算因子收益率，而因子暴露又是构建因子模拟组合的前提条件。这种矛盾似乎让人们陷入“先有鸡还是先有蛋”的怪圈。排序法最大的优势则在于它舍弃了“因子暴露已知”这个条件，从而绕过了上述“怪圈”。

下面以账面市值比（book-to-market ratio，BM，即市净率的倒数）这个经典的估值指标为例介绍排序法。虽然BM是一个估值指标，但依照学术界的惯例，将通过它构建的因子称为价值因子而非估值因子。本书遵循上述惯例。在排序法中，将股票排序的变量（比如BM）被称为排序变量（sort variable，简称变量）。排序法中最核心的思想是使用个股在该变量上取值的大小来代替个股在该因子上暴露的高低。需要强调的是，该方法并没有假设变量的取值等于因子暴露，也没有假设这二者之间满足某种特定的数学关系。该方法仅假设变量和因子暴露是相关联的。以BM为例，该方法认为高BM的股票在围绕BM构建的价值因子上的暴露更高，低BM的股票在围绕BM构建的价值因子上的暴露更低，仅此而已。在这个核心思想下，人们虽然不知道个股在该因子上的暴露，但是却可以通过变量的高低来代替它，并以此为依据构建因子模拟投资组合。这正是排序法的方便之处。同时，这也解释了排序法为什么仅适用于风格因子。对于其他类型的因子（比如宏观经济因子），由于难以从个股本身的数据出发找到和因子暴露相关的变量，自然也就无法使用这种方法。

前面说完了排序法的核心思想，下面马上来介绍它的具体方法。排序法的英文名字是portfolio sort，它的背后包含了“按变量将股票排序”“把股票依排序分组构建投资组合”以及“定期更新投资组合”三个步骤。

（1）排序：首先确定股票池，并将股票池中的全部股票在截面上按照排序变量（本例中的BM）的取值高低从大到小（或从小到大[1]）排序。

（2）分组：按排名高低将全部股票分为L组（依照惯例，一般根据变量取值分布的十分位数将全部股票分成10组，即L=10）。做多排名最高的第一组内的股票，并同时做空排名最低的最后一组内的股票而构建一个多、空对冲的投资组合，该投资组合又被称为价差组合（spread portfolio）。由构建方式可知，价差组合中多、空两头的收益率分别为变量取值最高的1/L股票的收益和变量取值最低的1/L股票的收益，它们的差异就反映了围绕该变量构建的因子的收益率。因此，价差组合正是使用排序法构建的因子模拟投资组合，而价差组合的收益率正是该因子的收益率。需要指出的是，在构建价差组合时，通常要求多、空两个组合的金额相同，即整个因子模拟投资组合是资金中性的[2]。此外，由于多、空两个投资组合都包含多支股票，因此需要为它们选择个股加权方式，其中最常见的是市值加权和等权重。

（3）定期更新：由于个股在变量上的取值并非一成不变的（即代表它们在该

因子上的暴露也是随时间变化的），因此需要定期进行上述两步，完成对因子模拟投资组合的更新。学术界通常称上述更新为再平衡（rebalance），且再平衡的频率多为每月或每年。在每期构建了新的因子模拟投资组合之后，计算该组合在当前时刻和下一个再平衡时刻之间的收益率。在时序上如此往复，就得到因子收益率的时间序列。

通过排序法，人们可以方便地构建因子模拟投资组合，计算因子收益率以及由排序法得到的L个投资组合的收益率。一旦有了这些数据，检验因子预期收益率，以及考察L个投资组合收益率的单调性就构成了检验的内容。学术界将上述检验称为投资组合排序检验（portfolio sort test）。下面依次说明这两个检验内容。

投资组合排序检验最重要的目的是检验因子预期收益率。在关于因子的研究中，原假设通常为因子预期收益为零。由第1章的定义可知，因子的预期收益率应该大于零。因此，检验关注的是依据样本数据计算出的因子收益率，能否在给定的显著性水平下拒绝原假设。令$\{\lambda_t\}$（t=1, 2, ⋯, T）代表因子收益率时间序列，则因子预期收益率的估计$\hat{\lambda}$以及其标准误（standard error）s.e.$_{(\hat{\lambda})}$分别为：

$$\hat{\lambda} = \frac{1}{T}\sum_{t=1}^{T}\lambda_t \tag{2.1}$$

$$\text{s.e.}(\hat{\lambda}) = \frac{\text{std}(\lambda_t)}{\sqrt{T}} \tag{2.2}$$

其中std（λ_t）表示λ_t的标准差。上式说明将$\{\lambda_t\}$在时序上取平均值就得到预期收益率的估计。有了$\hat{\lambda}$和s.e.$(\hat{\lambda})$，便可在原假设下（即λ=0）计算t-值（t-statistic），进行t-检验：

$$t\text{-值} = \frac{\hat{\lambda}}{\text{s.e.}(\hat{\lambda})} \tag{2.3}$$

它满足自由度为T-1的t分布。根据t-值和t分布可计算出（双尾）p-值，通过t-值或p-值就能够判定在给定的显著性水平下接受或拒绝原假设。依照学术界的惯例，通常使用0.05和0.01的显著性水平，在大样本下它们对应的t-值阈值分别约为2.0和2.6。因此，一旦样本数据计算出的收益率的t-值高于2.0，就认为该结果在原假设下是显著的[3]。如果原假设（因子预期收益率为零）无法被拒绝，那么被研究的因子就不满足预期收益率大于零的要求，因此t-值是否高于2.0就是一个重要的判定依据[4]。本书第3章到第5章的实证分析中将汇报检验结果的t-值。

除此之外，由于一个好的因子应能够解释个股超额收益的截面差异，因此排序法关注的第二个问题就是依照排序变量高低得到的L个投资组合的收益率是否有很好的单调性，这可以通过计算收益率和排序变量分组的秩相关系数（rank correlation coefficient）来检验。秩相关系数和相关系数类似，不同的是计算时将观测值转换为观测值的排位（rank），因此它考察的是两个随机变量之间的单调相关性。统计学中有多种计算秩相关系数的方法，其中最流行的要数Spearman秩相关系数（以Charles Spearman命名）。将L个投资组合的收益率的高低排位记为X_r、将它们依排序变量的分组的高低排位记为X_g，这二者的相关系数即为收益率和排

WPS PDF编辑试用

序变量分组的秩相关系数ρ_s：

$$\rho_s = \frac{\mathrm{cov}(X_r, X_g)}{\sigma_{X_r}\sigma_{X_g}} \tag{2.4}$$

从式（2.4）中不难发现，当L个投资组合的收益率随变量分组完美单调递增时，二者的秩相关系数为1；而当这些收益率随变量分组完美递减时，这二者的秩相关系数为-1。

下面仍以BM为例对上述检验进行说明。通过排序法将A股市场中的股票按照BM高低分为L=10组（记为Low，2，…，9，High，其中Low代表BM最低的一组、High代表BM最高的一组），每组内股票按总市值加权配置，每月再平衡[5]。此外，通过做多BM最高的一组（即High组）、做空BM最低的一组（即Low组）构建价值因子投资组合。表2.2给出了对价值因子预期收益率的检验结果，以及这10个投资组合预期收益率的检验结果（这是学术界的常见做法）。从检验结果可知，因子月均收益率为0.88%，标准误为0.47%，t-值为1.85，p-值为0.07，因此可以在0.1的显著性水平下拒绝原假设。

表2.2　BM排序检验结果

	Low	1	2	3	4	5	6	7	8	High	High−Low
均值（%）	0.57	0.53	0.57	0.72	0.94	0.90	1.08	1.32	1.21	1.44	0.88
标准误（%）	0.57	0.56	0.55	0.58	0.56	0.53	0.57	0.58	0.56	0.58	0.47
t-值	1.00	0.95	1.03	1.24	1.69	1.69	1.90	2.27	2.15	2.48	1.85
p-值	0.32	0.35	0.30	0.22	0.09	0.09	0.06	0.02	0.03	0.01	0.07

接下来，为了从视觉上更好地呈现单调性，图2.1展示了利用BM排序得到的10个投资组合的月均收益率，它们基本随BM的增加而变大。利用式（2.4）计算可知，这10个投资组合的收益率和BM分组的秩相关系数高达0.94（p-值为5.48×10^{-5}），表现出显著的单调性，且收益率和BM取值之间呈正相关。

由于简单易用，排序法在学术界和业界关于风格因子的研究中得到了广泛的应用。值得一提的是，在前文介绍排序法的时候默认的都是使用单一变量对股票排序，因此它也被称为单变量排序（univariate sorting）。但不要忘记，排序法仅仅是构建因子模拟投资组合的一个相对“粗暴”的方法。根据定义，因子模拟投资组合应该在非目标因子上没有暴露，然而排序法却难以控制其他因子的影响，这是它最大的缺点。举个假想的例子，如果高BM的股票全都是大市值股票、低BM的股票全都是小市值股票，那么当使用BM这个单一变量排序的时候，构建的价差组合在无形之中也同时做多了大市值股票、做空了小市值股票。因此，这个价差组合虽然是围绕BM构建的，但其收益率却受到BM和市值的共同影响，因而难以客观评估BM的贡献。为了尽可能排除其他因子的干扰，常见的做法是使用多个变量进行双重排序或三重排序，这些方法统称为多重排序法。

WPS PDF编辑试用

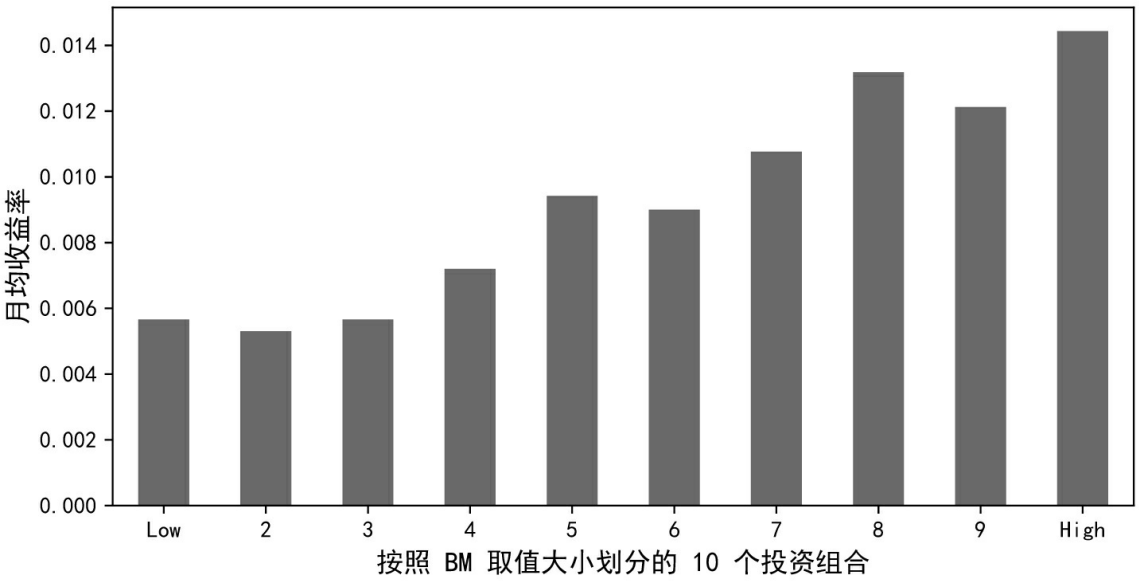


图2.1　按BM排序得到的10个投资组合的月均收益率

2.1.3　多重排序法

1. 双重排序

在多重排序法中，最重要的是双重排序（double sorting或bivariate sorting）。所谓双重排序，即按照两个变量排序并构建因子模拟投资组合。考虑两个排序变量X_1和X_2，将股票按照这两个变量分别划分为L_1和L_2组，一共得到$L_1 \times L_2$个组合。在双重排序时，一处非常关键的细节是使用这两个变量分别独立对股票排序，还是这两个变量在排序时存在先后的依存关系。前者被称为独立双重排序（independent double sorting或unconditional double sorting），或者被称为条件双重排序（dependent double sorting或conditional double sorting）。

首先来看独立双重排序的情况。假设使用两个排序变量分别独立地把股票划分成5组，即$L_1=L_2=5$，它们两两取交集一共得到25个投资组合，如图2.2中的P_{11}到P_{55}所示。在划分时，最常见的做法是取这两个变量各自的五分位数。这25个投资组合中股票的权重可以采用等权重或市值加权。接下来，通过这25个组合就可以围绕给定的变量构建因子模拟投资组合了。以X_1为例，构建的思路和单变量排序一样，仍然是做多在该变量上排名高的股票、做空在该变量上排名低的股票，并满足资金中性。由于采用了双重排序，因此对于变量X_2的每一档，都存在一个在变量X_1上排名高的投资组合。换句话说，一共有L_2（=5）个这样的组合，它们是P_{51}、P_{52}、P_{53}、P_{54}以及P_{55}。类似的，一共有L_2（=5）个在变量X_1上排名低的组合，它们是P_{11}、P_{12}、P_{13}、P_{14}以及P_{15}。最后，等权重做多L_2（=5）个高排名组合、做空L_2（=5）个低排名组合，就得到了围绕X_1构建的因子投资组合。令$R_{ij,t}$代表投资组合P_{ij}第t期的收益率，则该因子第t期的收益率$\lambda_{X_1 t}$为：

$$\lambda_{X_1 t} = \frac{1}{L_2}\sum_{i=1}^{L_2} R_{L_1 i,t} - \frac{1}{L_2}\sum_{i=1}^{L_2} R_{1i,t} \tag{2.5}$$

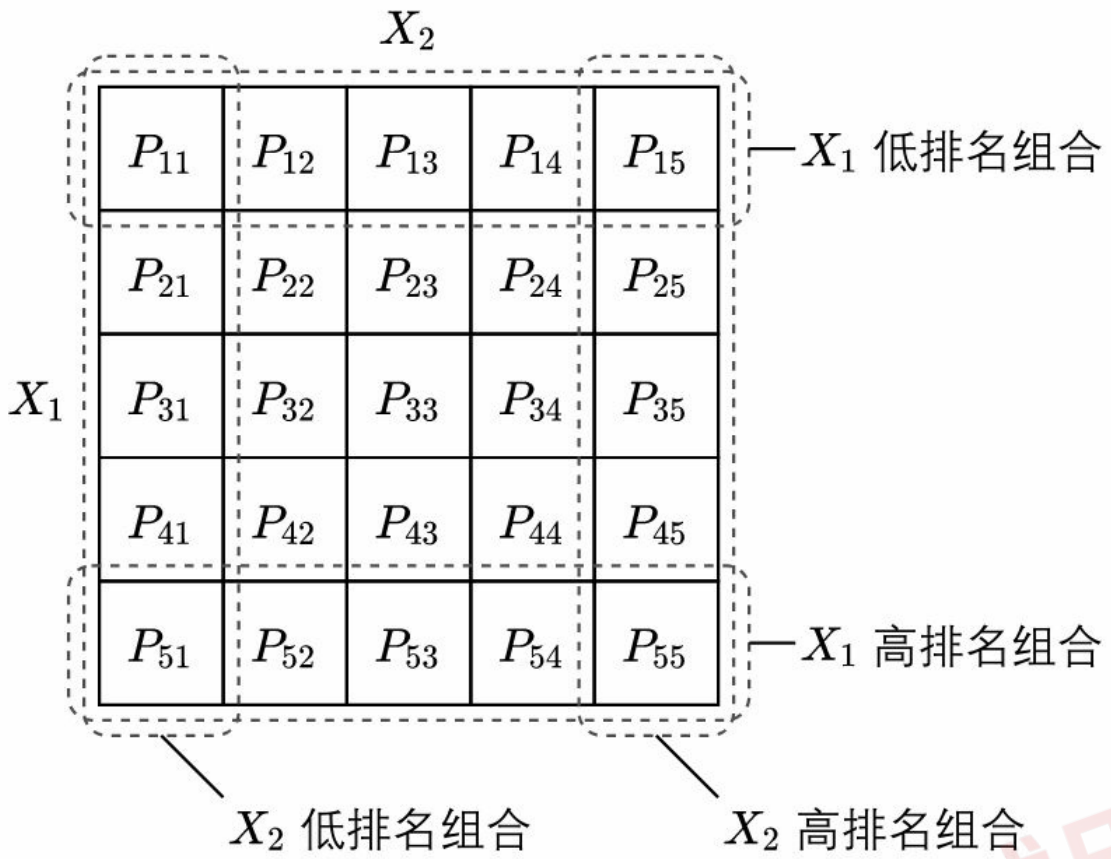


图2.2　独立双重排序法示例

在独立双重排序中，两个变量的地位是完全对称的，因此很容易就可以得到围绕X_2变量构建的因子投资组合，它通过做多L_1（=5）个在变量X_2上高排名组合（P_{15}、P_{25}、P_{35}、P_{45}以及P_{55}）、做空L_1（=5）个在变量X_2上低排名组合（P_{11}、P_{21}、P_{31}、P_{41}以及P_{51}）而构成，并满足资金中性。该因子第t期的收益率λ_{X_2t}为：

$$\lambda_{X_2t} = \frac{1}{L_1}\sum_{i=1}^{L_1} R_{iL_2,t} - \frac{1}{L_1}\sum_{i=1}^{L_1} R_{i1,t} \tag{2.6}$$

有了因子收益率λ_{X_1t}和λ_{X_2t}的时间序列，就可以像2.1.2节一样如法炮制，计算t-值并检验因子预期收益率。值得一提的是，如果把式（2.5）和式（2.6）中的投资组合收益率重新排列一下，就可以得到另一种等价的形式：

$$\lambda_{X_1t} = \frac{1}{L_2}\sum_{i=1}^{L_2} (R_{L_1i,t} - R_{1i,t}) \tag{2.7}$$

$$\lambda_{X_2t} = \frac{1}{L_1}\sum_{i=1}^{L_1} (R_{iL_2,t} - R_{i1,t}) \tag{2.8}$$

下面以式（2.7）为例进行解读。它表示从每一个X_2变量分组i内挑出X_1变量排名最高和最低的两组，即R_{L_1i}和R_{1i}，并计算它们的差$R_{L_1i} - R_{1i}$。然后把一共L_2（本例中是5）个$R_{L_1i} - R_{1i}$取平均，就得到λ_{X_1t}。式（2.7）和式（2.5）的区别是，式

（2.5）是对这5个高排位和5个低排位投资组合“先分别取平均、再做差”，而式（2.7）则是将它们两两“先做差、再取平均”。在数学上，这两种方式完全是等价的，而式（2.5）的方式也确实是常见的计算因子收益率的方法[6]。但是，之所以介绍式（2.7）和式（2.8）这种表达式，是因为它们经常被用于对异象的研究中。

在学术界针对美股市场异象的研究中，双重排序法经常被使用。为了检验一个新的异象变量可以获得超额收益，学者们往往用它和已有的因子变量进行双重排序，从而排除已有因子的影响。在进行分析时，学者们除了关心异象收益率之外，还关心在已有因子变量的每组内，该异象变量是否能区分股票收益率的截面差异。回到上面X_1和X_2的例子，为检验能否通过X_1构建异象，应考察在每个X_2分组内，根据X_1划分的L_1个分组中最高和最低的组的收益率差异是否显著[7]。在这种情况下就会关心每个$R_{L_1 i}$-R_{1i}的取值。以上就是式（2.7）和式（2.8）这两种表达式也存在的原因。但再次强调的是，当使用独立双重排序法时，无论使用哪种表达式都不影响$\lambda_{X_1 t}$和$\lambda_{X_2 t}$的计算结果。

独立双重排序虽然简单，但它也有一个缺点，即独立排序可能导致某些组合包含的股票数目过少。举个例子，假设共有1000支股票，按照X_1和X_2两变量各分为5组，得到25个组合，平均下来每个组合包含40支股票。当X_1和X_2的截面相关性很高时，那么当一支股票在X_1变量取值较高时，它在X_2上的取值也会较高。这就会造成这两个变量相同的分组中——图2.2中对角线上的组——的股票个数较多，而其他组内（特别是高X_1、低X_2组以及低X_1、高X_2组）的股票个数较少。这种分组内股票数量的不平衡将使得最终的因子收益受异常值影响的可能性更高，造成因子收益率的不稳定并且也会影响在实践中的实施[8]。在实际研究因子时，上述缺点虽然存在，但通常不会带来太大的问题。这是因为人们通常不会使用截面相关性高的变量做双重排序。当对参与排序的两个变量的相关性不确定时，可以计算每组内股票的数量。如果全部$L_1 \times L_2$个投资组合均包含足够多的股票，那么就没有太大的问题。

接下来介绍条件双重排序。它与独立双重排序最大的区别是按照给定的顺序先后使用两个变量对股票进行排序。仍然以X_1和X_2两个变量为例。假设先用X_1排序将全部股票划分成L_1组。接下来，在以上每个组内，再用X_2排序把属于该组内的股票进一步划分为L_2个组，最终得到$L_1 \times L_2$个分组。从这个例子中不难看出，条件双重排序是考察当X_1控制之后，变量X_2对股票收益率的影响。反之，如果按照先用X_2排序、再用X_1排序，那就是在考察控制了X_2之后，变量X_1对股票收益率的影响。

条件双重分组关心的是当第一个变量被控制之后，第二个变量是否对解释收益率有增量信息。在这种方法中，两个排序变量的地位是不对称的：第一个排序变量仅仅作为控制变量，人们关心的是第二个排序变量和收益率之间的关系，因此只需（也只应）围绕第二个排序变量构建因子并计算因子收益率[9]。

在条件双重排序方法中，学术界通常使用以下两种方法为第二排序变量计算因子收益率。第一种方法和独立双重排序法中的收益率公式并无不同。假设X_1和X_2分别为第一、第二排序变量，则围绕X_2构建的因子收益率就如式（2.6）或式（2.8）所示（如果需要计算X_1的因子收益率，只需将两个排序变量的先后顺序调换）。除此之外，还有另外一种方法。仍以X_1和X_2分别为第一、第二排序变量为例。在这种方法中，将全部L_1个X_2排名最高的组，即P_{iL2}（i=1, 2, ⋯, L_1），以及L_1

个X_2排名最低的组，即P_{i1}（i=1, 2, ⋯, L_1），分别取并集：

$$P_{L_2}^{\text{top}} = P_{1L_2} \cup P_{2L_2} \cup \cdots \cup P_{L_1L_2} \tag{2.9}$$

$$P_{L_2}^{\text{bottom}} = P_{11} \cup P_{21} \cup \cdots \cup P_{L_11} \tag{2.10}$$

将$P_{L_2}^{\text{top}}$中的全部股票按照市值加权或等权重配置，构成变量X_2的多头；将$P_{L_2}^{\text{bottom}}$中的全部股票按同样的加权方式配置，构成变量X_2的空头。在每一期t，多头组合收益率（记为$R_{L_2}^{\text{top}}$）减去空头组合收益率（记为$R_{L_2}^{\text{bottom}}$），就是在这种方法下围绕变量X_2构建的因子的收益率：

$$\lambda_{X_2t} = R_{L_2}^{\text{top}} - R_{L_2}^{\text{bottom}} \tag{2.11}$$

这两种计算X_2（即第二排序变量）因子收益率的方法虽略有不同，但仔细比较它们不难发现，当每个投资组合中的股票都按照等权重配置时，式（2.6）和式（2.11）则是完全等价的。只有当每个投资组合采用非等权重（比如市值加权）时，这两种方法才略有差异。假设每个投资组合内股票按市值加权配置，当使用式（2.6）时，它多、空两头各自的L_1个投资组合仍然按照等权重配置；而当使用式（2.11）时，它首先把所有属于多头和空头的股票都挑出来，然后再按照市值加权配置。

最后值得一提的是，条件双重排序的规则保证了每组内都有足够多的股票。在本节的例子中L_1=L_2=5，如果假设这5组是按照排序变量的五分位数划分的，那么条件双重排序得到的25个投资组合中有相同数量的股票。在更一般的情况中，两个变量划分的组数可以不同，且每个变量用来划分的分位数也可能有差异，在这时不同组内的个股数量会有差异，但仍然能够保证有足够多的股票。

2. 两点说明

关于双重排序，还有两点补充说明。第一点说明，使用双重排序的目的是排除两个变量之间的相互影响，从而更准确地计算围绕每个变量构建的因子模拟投资组合的收益率。在这方面，条件双重排序比独立双重排序是更好的选择，因为它是在控制了第一个分类变量后、考察第二个分类变量和股票收益率的条件关系。然而，学术界在研究因子时，往往更习惯使用独立双重排序。这可能与最初经典的Fama and French（1993）三因子模型使用了独立排序有关。另外，当研究异象时，为了排除小市值的影响，使用市值和异象变量进行条件双重排序、构建异象投资组合并计算其超额收益也并不罕见。而在这些研究中，两种计算收益率的方法均有使用。举例来说，Bali et al.（2014）在研究尾部风险异象时采用式（2.6）计算异象收益率；而Liu et al.（2019）则使用式（2.11）研究并计算了一系列异象投资组合的收益率。

第二点说明是关于双重排序时两个变量划分的分组数。当学术界研究异象时，当股票池中的股票数量很大时，5×5或10×10都是常见的分组方式。但是当学术界研究因子时，往往采用2×3的划分，且变量之一是股票的市值。这种处理方法也和Fama and French（1993）三因子模型不无关系。由于该文是多因子模型的开

山鼻祖，它的很多处理方法对学术界都有着非常深远的影响。Fama and French（1993）在构建规模（SMB）和价值（HML）两个因子[10]时，采用市值和BM进行独立双重排序。在排序时，该文按市值把股票分成了大、小市值两组，按BM把股票分成高、中、低三组，最后两两交集构建了2×3=6个投资组合。这种使用市值和另外一个变量进行2×3划分的独立双重排序在Fama and French（1993）之后得到了广泛的应用，本书第4章会详细介绍。

3. 三重排序

除前面介绍的双重排序之外，近年也有部分研究采用了三重排序（triple sorting）。一个典型例子是Hou et al.（2015）提出的四因子模型。该文从实体投资经济学理论出发推导出预期收益率和投资以及盈利之间的条件关系。此外，考虑到盈利能力和投资效应在小盘股中都更强，为了排除市值的影响，Hou et al.（2015）在构建因子时，使用规模、投资和盈利三个维度的变量进行了三重排序。

排序法及其检验是因子研究中最常见的方法之一。它最大的好处是绕过因子暴露，构建因子模拟投资组合、计算因子收益率。它是通过时间序列回归检验股票多因子模型的基础。在结束2.1节之前，最后再来讨论一个问题：因子命名。

2.1.4 因子命名约定

因子命名本身并无严格的要求。但之所以需要约定一个命名方式，是因为无论是在学术界的研究还是业界的实践中，对同一个因子往往有很多不同的称呼。仍以BM为例。在Fama and French（1993）三因子模型中，两位作者使用BM和市值双重排序构建了一个HML因子。HML是High-Minus-Low的首字母缩写，而其中High代表BM高的股票，Low代表BM低的股票，Minus代表做多前者、做空后者。显然，人们也可以把它称作BM因子——这个名字以构建因子的变量为出发点；又或者把它称为价值[11]因子——这个名字以该变量代表的股票风格（style）为出发点。无论是叫HML因子、BM因子还是价值因子，它们指代的都是同一个因子模拟投资组合、同一个因子。为了本书前后一致性，本小节对书中使用的因子命名方法进行说明。在因子命名时，考虑的因素是命名的方便程度以及名字是否能清晰地传达因子的含义。

首先，本书不采用Fama and French（1993）的命名方法，原因如下。任何一个变量排序都可以把股票分成高、中、低不同的分组，并构建一个High-Minus-Low组合。如果大家都叫HML因子，则无法加以区分。举例来说，在Fama and French（2015）五因子模型中包括使用BM构建的HML因子和使用ROE构建的盈利因子。Fama and French（2015）将ROE和市值一起进行双重排序，并通过做多高ROE的组同时做空低ROE的组构建了该盈利因子。由于High和Low两个词已经被HML因子占用了，Fama and French（2015）则想出了使用稳健（Robust）和疲软（Weak）来代表高、低两个ROE组合，并以Robust-Minus-Weak即RMW为该因子命名。这种做法的优点是，它能体现变量和收益率之间是正相关还是负相关。比如无论是HML还是RMW，都代表变量高取值组和变量低取值组的差异，这意味着BM或ROE和股票收益率呈现正相关。而在Fama and French（1993）中，代表规模的SMB因子是Small-Minus-Big的缩写，它则表示市值和收益率呈现负相关，即小

市值股票的预期收益率高于大市值股票。尽管有这一优点，然而一旦人们真正理解了因子背后的原因，就不再需要依靠其命名来暗示变量和收益率的关系。且考虑到这种做法在因子数量越来越多的时候将会对因子命名造成不便，因此本书放弃这种方法。

使用变量本身和使用其代表的风格命名在方便程度上并无太大差异，但由于以下两个原因，本书作者认为后者更合理。首先，如前所述，风格因子在股票市场中占主宰地位。学术界和业界的绝大多数研究都是关于风格因子。因此，风格比变量本身能更清晰地传达出因子所代表的含义。其次，在业界的因子投资实践中，出于稳健性的考虑，往往使用多个指标构建某种风格的因子。比如，业界会同时使用BM和盈利市值比（earnings-to-priceratio，即EP）等多个估值指标构建价值因子。在这种情况下，选择某个指标对因子命名就会以偏概全。

出于上述考量，本书选择以变量代表的风格为出发点对因子进行命名。举例来说，按照本书的约定，将会称使用BM构建的因子为价值因子，使用ROE构建的因子为盈利因子。

[1]排序法的第二步将会通过做多排名靠前的股票、做空排名靠后的股票构建因子模拟投资组合。一般认为因子的风险溢价为正。这意味着在排序时通常从金融学和经济学原理考虑变量和收益率之间的相关性。如果变量和收益率呈现负相关，则往往按变量取值从小到大将股票排序。低波动因子就是这样一个例子。

[2]在针对以美元计价的美股研究中，将其称为dollar neutral。

[3]由t分布的对称性可知，如果t-值小于−2.0也可以认为结果在原假设下是显著的。

[4]本书6.1节将介绍学术界的最新研究成果，它们将单个因子检验的t-值阈值提升到3.0以上。

[5]本书的第3章将会详细说明实证分析中的数据处理方式。

[6]比如经典的Fama and French（1993）三因子模型就使用了这种表达式。本书第4章会详细说明。

[7]除此之外，研究人员也会关心每个给定的X_2分组下，以X_1排序划分的L_1个投资组合的收益率是否呈现出很好的单调性。

[8]在某些极端情况下，X_1和X_2的某种分组组合的交集甚至可能为空，即没有任何股票。

[9]Bali et al.（2016）指出在条件双重排序法中为第一排序变量构建因子并计算因子收益率有很大的不确定性。

[10]本书第4章会详细介绍包括Fama and French（1993）三因子模型在内的主流多因子模型。

[11]BM本身是一个估值指标。但因为它常被用在价值投资（value investing）中衡量公司估值是否过高，因此无论是学术界还是业界，通常把它称为价值因子。

WPS PDF编辑试用

2.2 多因子模型的回归检验

使用2.1节介绍的排序法，人们可以很容易地针对股票风格因子构建因子投资组合并计算其收益率。然而，多因子模型中最核心的问题是检验一系列因子解释异象的能力。本节就来说明如何使用回归的方法检验多因子模型，其中涉及的不同方法包括时序回归检验、截面回归检验以及Fama and MacBeth（1973）回归检验[1]。

在下文的介绍中，令N和K分别代表资产和因子的个数。回顾一下本书第1章中的式（1.3），它指出资产预期（超额）收益和因子预期收益率之间满足如下关系：

$$E[R_i^e] = \alpha_i + \boldsymbol{\beta}_i'\boldsymbol{\lambda} \tag{2.12}$$

其中R_i^e代表资产[2] i的超额收益，β_i为资产i的K维因子暴露向量；λ为K维因子预期收益率向量。多因子模型研究的核心问题是资产预期收益率在截面上——即不同的资产之间——为什么会有差异。根据模型（2.12），如果一个资产在因子上的暴露β_i高，则它的预期收益$E[R_i^e]$也应该更高。

再来仔细品一品这句话，即多因子模型（2.12）研究的是资产预期收益率在截面上的差异。站在本书提出的统一视角下，这是从截面角度来研究多因子模型的。在检验模型（2.12）时，不关心资产的收益率R_i^e在时间序列上是如何随着每期因子收益率来波动的，只关心R_i^e的期望$E[R_i^e]$在截面上和对应的β_i之间的关系，因为模型（2.12）是关于均值的模型。多因子模型中所包含的因子代表了收益率的一种结构。一旦结构给定后，个股或者任何一个投资组合的预期收益率就完全由它在这些因子上的暴露决定了——暴露高，预期收益率就高；预期收益率是因子暴露的线性函数。怎样找到最好的因子结构，即哪些因子使得个股在截面上的预期收益率区分度高，并让不能被该模型解释的定价误差α_i部分尽可能低，就是多因子模型研究的问题。

仍然晦涩？用图2.3解释一下（因为要做图，所以假设单因子模型）。图中横坐标为β_i，纵坐标为$E[R_i^e]$，每个点代表一个资产。图中这条直线就代表$E[R_i]=\beta_i\lambda$，它的斜率λ就是因子的预期收益率。当模型不能被完美地满足时，资产的预期收益率$E[R_i]$和模型算出的$\beta_i\lambda$之间就会存在误差，它就是图中的α_i。

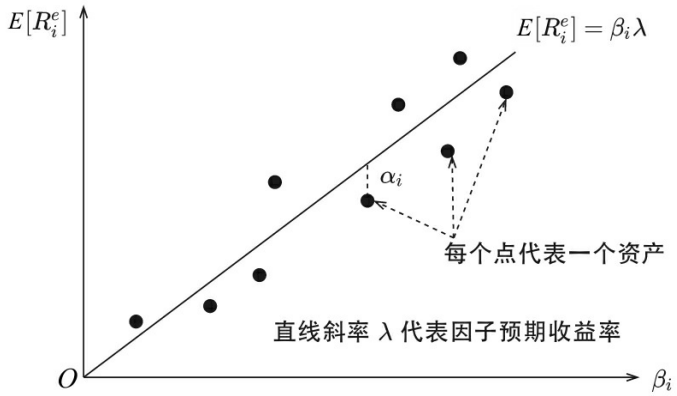


图2.3　截面上股票预期收益率和风险暴露的关系

正如前文反复强调的，多因子模型反映的是预期收益率和因子暴露在截面上的关系。在多因子模型被提出之前，人们最熟悉的因子模型无疑是CAPM。它因为只有一个市场因子，所以是多因子模型的一个特例。人们最早的猜测是市场因子的收益率和个股在该因子上的β就可以解释截面上不同股票收益率之间的区别。但大量的实证结果显示如果把个股的$E[R_i^e]$和它们针对市场因子的β_i画出来，二者之间的关系并不能很好地满足该模型，说明仅仅用单一市场因子无法很好地解释$E[R_i^e]$在截面上的差别。为了反映这一现象，Black et al.（1972）在CAPM的基础上又加入了一个zero-beta因子，该两因子模型能够更好地解释$E[R_i^e]$在截面上的差别[3]。再后来，Fama and French（1993）提出了大名鼎鼎的三因子模型，它在市场因子的基础上加入价值（HML）和规模（SMB）两个因子。这些努力都是为了能够更好地解释人们在股票收益率数据中观察到的$E[R_i^e]$在截面上的差别。

之所以回顾上面这一小段历史，是为了说明学术界在多因子模型上的各种努力都是为了更好地解释$E[R_i^e]$为什么会因资产而异。那么，拿来一个多因子模型，如何定量地评估它是否是一个好的模型呢？为了回答这个问题，首先来看检验中的三个部分：估计值（estimate）、标准误（standard errors）以及检验（test），见表2.3。

表2.3　多因子模型检验的三个部分

任务	说明
估计值	$\hat{\alpha}_i$, $\hat{\boldsymbol{\beta}}_i$, $\hat{\boldsymbol{\lambda}}$
标准误	$\sigma(\hat{\alpha}_i)$, $\sigma(\hat{\boldsymbol{\beta}}_i)$, $\sigma(\hat{\boldsymbol{\lambda}})$
检验	联合检验所有 N 个资产的定价误差；检验每个因子的预期收益率

对于截面关系式$E[R_i^e]=\alpha_i+\boldsymbol{\beta}_i'\boldsymbol{\lambda}$，下文将采用回归分析（regression analysis）来确定$\hat{\alpha}_i$、$\hat{\boldsymbol{\beta}}_i$、$\hat{\boldsymbol{\lambda}}$和$\sigma(\hat{\alpha}_i)$、$\sigma(\hat{\boldsymbol{\beta}}_i)$、$\sigma(\hat{\boldsymbol{\lambda}})$。一旦有了估计值和标准误，就可以用它们检验多因子模型。由式（2.12）可知，α_i代表了资产i的定价误差。如果能够在统计上证明所有α_i都很接近零，则可以说该多因子模型就是很好的模型，即它能够解释资产预期收益率的截面差异。由此可见，多因子模型的回归检验中最重要的就是检验所有α_i联合起来是否在统计上足够接近零。除此之外，使用λ的估计值和标准误，同样可以检验每个因子的预期收益率[4]。根据上述说明，多因子模型的回归检验可以简单总结为以下三步：

（1）计算每个资产在所有因子上的暴露β_i；

（2）通过回归分析对多因子模型进行估计；

（3）联合检验资产定价误差α_i以及每个因子的预期收益率λ_k。

无论选择哪些因子（诸如风格因子或宏观经济因子），也无论在确定截面关系时采用时序回归还是截面回归，对多因子模型的检验最终都可以按照上述三步完成。下面先来看看时间序列回归检验。

2.2.1 时间序列回归

时间序列回归（time-series regression）简单直接，Black et al.（1972）最早使用它来检验CAPM。这种方法在回归时使用因子收益率作为自变量（independent variable）或解释变量（explanatory variable），以资产的超额收益率作为因变量（dependent variable）或被解释变量（explained variable）。

此方法更适合分析由风格因子构成的多因子模型，这是因为人们可以使用2.1节介绍的排序法构建风格因子的因子模拟投资组合，并计算其收益率作为解释变量。对于其他类别的因子，比如GDP等宏观经济因子，由于难以应用排序法构建它的因子模拟投资组合以及计算收益率，所以这种方法就无法使用，举例来说，Fama and French（1993）中的价值（HML）和规模（SMB）因子均是风格因子。该文使用独立双重排序构建了这两个因子的投资组合，并计算了它们的收益率时间序列，使用它们就可以方便地进行时间序列回归检验。

令λ_t表示t期因子收益率向量，R_{it}^e为资产i在t期的超额收益率，这二者在时序上满足如下线性关系：

$$R_{it}^e = \alpha_i + \boldsymbol{\beta}_i'\boldsymbol{\lambda}_t + \varepsilon_{it}, \quad t = 1, 2, \cdots, T \tag{2.13}$$

对每个资产i=1, 2, ⋯, N，使用简单最小二乘（Ordinary Least Squares，OLS）对模型（2.13）进行参数估计。在时间序列回归中，回归方程右侧自变量是因子收益率λ_t，左侧的因变量是R_{it}^e，回归得到资产i在因子上的暴露$\hat{\beta}_i$向量，截距$\hat{\alpha}_i$，以及残差$\hat{\varepsilon}_{it}$。一旦有了$\hat{\alpha}_i$和$\hat{\beta}_i$，将R_{it}^e和λ_t在时序上取均值就可得：

$$E_T[R_i^e] = \hat{\alpha}_i + \hat{\boldsymbol{\beta}}_i'\hat{\boldsymbol{\lambda}}, \quad i = 1, 2, \cdots, N \tag{2.14}$$

式中$E_T[.] \equiv \frac{1}{T}\sum(.)$表示对样本数据在时序上取均值；$\hat{\boldsymbol{\lambda}} = ET[\hat{\boldsymbol{\lambda}}_t]$是资产预期收益率和因子暴露在截面上的关系式。时间序列回归中的截距$\hat{\alpha}_i$正是资产i的定价误差的估计。由（2.14）可知，时间序列回归的好处是可以方便地估计每个因子的预期收益率。对于任意因子k，其收益率序列λ_{kt}在时序上的均值就是因子k预期收益率的估计：

$$\hat{\lambda}_k = ET[\lambda_{kt}], \quad k = 1, 2, \cdots, K \tag{2.15}$$

下面仍然以单因子这种最简单的情况来画图，说明上述时间序列回归得到的$E[R_i^e]$和β_i的截面关系长什么样子。图2.4中的直线为$E[R_i^e]=\beta_i\lambda$：当$\beta_i=0$时，$E[R_i^e]=0$；此外，如果用该模型解释因子投资组合本身（即将因子投资组合视作一个资产放在截面关系式的左侧），且根据定义因子投资组合在自身上的暴露为1（即$\beta_i=1$），因而有$\lambda=0+1\times\lambda$。以上论述说明，时间序列回归得到的$E[R_i^e]=\beta_i\lambda$这条直线一定会经过（0, 0）和（1, λ）两点。

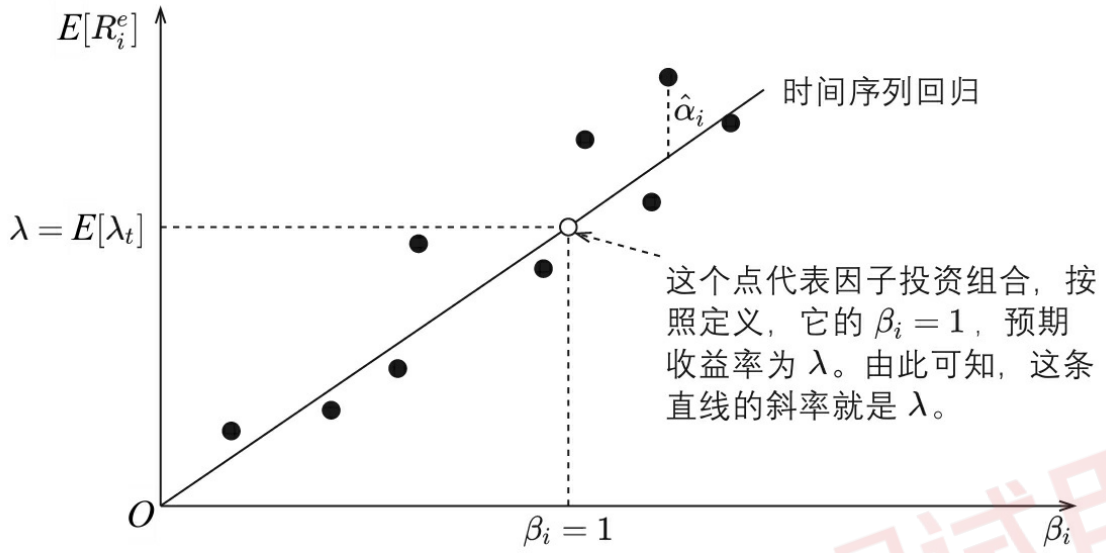


图2.4　时序回归示意图

图2.4中所有黑色的实心圆点代表着资产，空心的点代表着因子投资组合。时间序列回归得到的多因子模型$E[R_i^e]=\beta_i\lambda$就是经过原点和空心点的那条直线。所有资产到这条直线的距离就是资产的$\hat{\alpha}_i$。需要特别强调的是，在使用时间序列回归时，需对每个资产i分别独立用多因子模型进行时序回归。因此图2.4中的这条直线并不是以最小化$\hat{\alpha}_i$的平方和为目的求出的，这是时序回归和本书2.2.2节介绍的截面回归的最大差别（截面回归是以最小化所有$\hat{\alpha}_i$的平方和为目标的）。

有了时序回归模型，下一步就是计算各种参数的标准误，并进行检验。当随机扰动ε_{it}不存在自相关（autocorrelation）或异方差（heteroskedasticity）时，时序回归参数的标准误可以由OLS的标准公式给出。进一步的，假设ε_{it}满足IID正态分布[5]，Michael Gibbons、Stephen Ross以及Jay Shanken在Gibbons et al.（1989）一文中给出了检验α_i是否联合为零的方法。即便到了今天，该方法仍然是学术界检验和比较因子模型时的首选方法，由于影响深远，所以该方法也由三位教授姓氏的首字母命名为GRS检验。

在GRS检验中，原假设所有α_i均为零。定义向量$\hat{\boldsymbol{\alpha}}=[\hat{\alpha}_1,\hat{\alpha}_2,\cdots,\hat{\alpha}_N]'$以及$\hat{\boldsymbol{\varepsilon}}_t=[\hat{\varepsilon}_{1t},\hat{\varepsilon}_{2t},\cdots,\hat{\varepsilon}_{Nt}]'$。GRS检验构建了如下满足自由度为$T$-$N$-$K$和$N$的$F$分布的检验统计量（称为GRS test statistic）：

$$\frac{T-N-K}{N}\left(1+E[\boldsymbol{\lambda}_t]'\hat{\boldsymbol{\Sigma}}_\lambda^{-1}E[\boldsymbol{\lambda}_t]\right)^{-1}\hat{\boldsymbol{\alpha}}'\hat{\boldsymbol{\Sigma}}^{-1}\hat{\boldsymbol{\alpha}}\sim F_{N,T-N-K}$$

其中 $\hat{\boldsymbol{\Sigma}}_\lambda=\frac{1}{T}\sum_{t=1}^{T}[\boldsymbol{\lambda}_t-E[\boldsymbol{\lambda}_t]][\boldsymbol{\lambda}_t-E[\boldsymbol{\lambda}_t]]'$ (2.16)

$$\hat{\boldsymbol{\Sigma}}=\frac{1}{T}\sum_{t=1}^{T}\hat{\boldsymbol{\varepsilon}}_t\hat{\boldsymbol{\varepsilon}}_t'$$

有了检验统计量，只需要利用F分布计算出它的p-值就可以判断是接受还是拒绝原假设。需要说明的是，一旦ε_{it}之间存在相关性或者异方差，传统OLS的标准误公式就是错误的，且上述检验统计量也是有问题的。在这种情况下，可以采用更强大的计量经济学工具——比如广义矩估计（2.7节会介绍）——来进行检验。尽管如此，GRS检验仍然是非常普及的一种方法。

除了检验α_i是否联合为零外，另一个目标是考察每个因子的预期收益率。由于时序回归假设因子收益率的时间序列已知，因此只需要参照2.1.2节的介绍对每个因子的收益率进行t-检验即可，此处不再赘述。最后对时间序列回归检验简要总结如下。

（1）因子收益率时序需已知。使用因子收益率作为解释变量，分别对每个资产进行时序回归，得到该资产在这些因子上的暴露的估计$\hat{\boldsymbol{\beta}}_i$；时序回归中的$\hat{\alpha}_i$（截距项）就是截面关系上资产的定价误差。

（2）将时序回归结果在时间上取均值，就得到资产预期收益率和因子暴露在截面上的关系。由于时序回归是对每个资产单独进行的，因此该关系的确定不以最小化所有$\hat{\alpha}_i$的平方和为目标。

（3）若（2.13）中的ε_{it}满足IID正态分布，则可以通过GRS方法构建F-统计量来检验α_i联合是否在统计上为零，否则可以通过广义矩估计等更高级的方法；对于因子预期收益率，可使用t-检验来分析。

2.2.2 截面回归

时间序列回归虽然很方便，但它以因子收益率时序已知为前提。这意味着它更适合处理股票的风格因子，而对诸如GDP、CPI以及利率这样的宏观经济因子无能为力。这时可以选择截面回归（cross-sectional regression）来检验多因子模型，它能够方便地处理因子收益率时序未知的情况。截面回归检验的最终目的自然还是考察$E[R_i^e]$和β_i在截面上的关系，但此方法的第一步仍然是利用时序回归确定资产的因子暴露。

假设t期一组因子的取值为$f_t=[f_{1t}, f_{2t}, \cdots, f_{Kt}]'$（$K$维阶向量）。首先通过如下时序线性回归模型确定因子暴露：

$$R_{it}^e=a_i+\boldsymbol{\beta}_i'\boldsymbol{f}_t+\varepsilon_{it},\quad t=1,2,\cdots,T,\forall i \tag{2.17}$$

WPS PDF编辑使用

需要说明的是，在模型（2.17）中，截距项用了符号a_i，而非像式（2.13）中的α_i。这是因为如果模型（2.17）中的解释变量不是因子收益率，则它的截距项就不是定价误差。采用OLS对模型（2.17）进行估计，在得到资产的因子暴露$\hat{\boldsymbol{\beta}}_i$以及残差$\hat{\varepsilon}_{it}$。之后，进入本方法的第二步：截面回归。在这一步中，使用第一步得到的因子暴露的估计$\hat{\boldsymbol{\beta}}_i$作为解释变量，以资产收益$R_{it}^e$在全部$T$期上的时序平均（记为$E_T[R_{it}^e]$）作为被解释变量，$E_T[R_i^e]$和$\hat{\boldsymbol{\beta}}_i$在截面上满足的线性回归模型为：

$$E_T[R_i^e] = \hat{\boldsymbol{\beta}}_i'\boldsymbol{\lambda} + \alpha_i, \quad i = 1, 2, \cdots, N \tag{2.18}$$

使用OLS求解模型（2.18）就可以得到因子预期收益率的估计$\hat{\boldsymbol{\lambda}}$，以及每个资产的定价误差的估计$\hat{\alpha}_i$。细心的读者可能发现，在模型（2.18）中并没有出现截距项，而是使用回归的残差直接作为定价误差$\hat{\alpha}_i$。这背后的原因是多因子模型假定当不存在模型设定偏误时，资产的预期收益率应该仅由因子暴露和因子预期收益率决定。当然，公式是“死的”，应用是“活的”，Cochrane（2005）指出在进行模型（2.18）截面回归时，也可以考虑包含截距项。加入截距项后，模型（2.18）变为：

$$E_T[R_i^e] = \gamma + \hat{\boldsymbol{\beta}}_i'\boldsymbol{\lambda} + \alpha_i, \quad i = 1, 2, \cdots, N \tag{2.19}$$

仍以单因子为例，图2.5展示了通过截面回归得到的资产预期收益率和因子暴露的截面关系。如果使用OLS对模型（2.18）进行估计，则图2.5中截面回归得到的关系将通过原点并最小化所有残差的平方和。

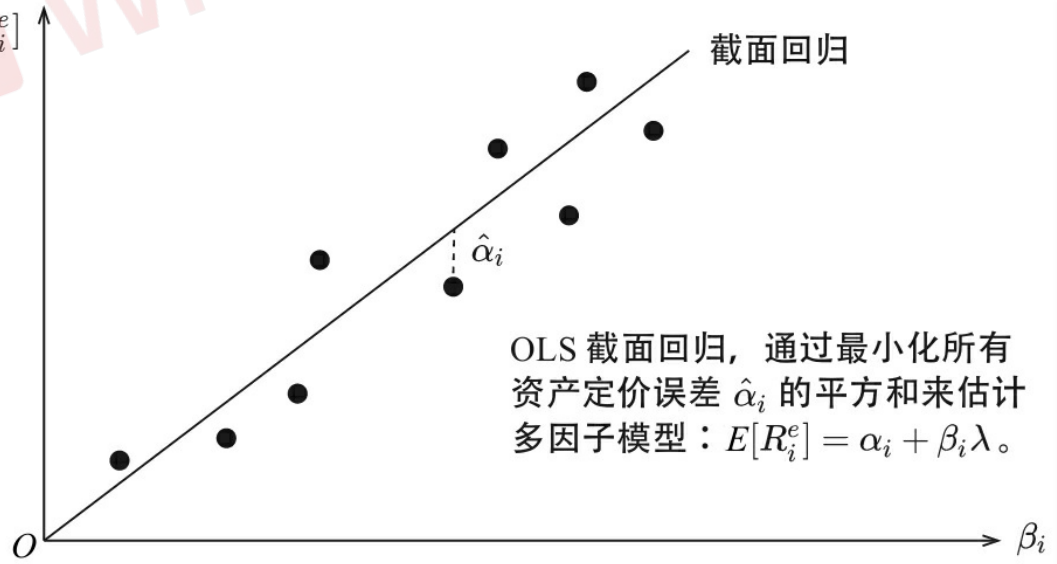


图2.5　截面回归示意图

为了更方便地给出数学公式，定义全部N个资产在这K个因子上的因子暴露矩阵$\hat{\boldsymbol{\beta}} \equiv [\hat{\boldsymbol{\beta}}_1, \hat{\boldsymbol{\beta}}_2, \cdots, \hat{\boldsymbol{\beta}}_N]'$，它是$N \times K$矩阵；定义$N$维向量$\hat{\boldsymbol{\alpha}} \equiv [\hat{\alpha}_1, \hat{\alpha}_2, \cdots, \hat{\alpha}_N]'$，和$N$维向量$E_T[\boldsymbol{R}^e] \equiv [E_T[R_1^e], E_T[R_2^e], \cdots, E_T[R_N^e]]'$。利用上述数学符号，截面回归模型（2.18）的OLS估计量为：

WPS PDF编辑试用

$$\hat{\boldsymbol{\lambda}} = \left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}' E_T[\boldsymbol{R}^e] \tag{2.20}$$

$$\hat{\boldsymbol{\alpha}} = E_T[\boldsymbol{R}^e] - \hat{\boldsymbol{\beta}}\hat{\boldsymbol{\lambda}} \tag{2.21}$$

为了联合检验所有定价误以及每个因子的预期收益率，仅知道$\hat{\boldsymbol{\lambda}}$和$\hat{\boldsymbol{\alpha}}$是不够的，还需要求出它们各自的标准误。令$\varepsilon_t=[\varepsilon_{1t},\ \varepsilon_{2t},\ \cdots,\ \varepsilon_{Nt}]'$（$\varepsilon_{it}$是时序线性模型（2.17）中的随机扰动，且定义$\Sigma_f$=cov（$f_t$）以及$\Sigma$=cov（$\varepsilon_t$），利用它们并假设$f_t$和$\varepsilon_t$之间相互独立，且它们各自在时序上满足独立同分布，Cochrane（2005）给出了$\hat{\boldsymbol{\lambda}}$和$\hat{\boldsymbol{\alpha}}$的协方差矩阵：

$$\mathrm{cov}(\hat{\boldsymbol{\lambda}}) = \frac{1}{T}\left[\left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}'\boldsymbol{\Sigma}\hat{\boldsymbol{\beta}}\left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1} + \boldsymbol{\Sigma}_f\right] \tag{2.22}$$

$$\mathrm{cov}(\hat{\boldsymbol{\alpha}}) = \frac{1}{T}\left[\boldsymbol{I} - \hat{\boldsymbol{\beta}}\left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}'\right]\boldsymbol{\Sigma}\left[\boldsymbol{I} - \hat{\boldsymbol{\beta}}\left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}'\right]' \tag{2.23}$$

在实际中，由于真实的Σ和Σ_f未知，故可采用残差向量$\hat{\varepsilon}_t = [\hat{\varepsilon}_{1t}, \hat{\varepsilon}_{2t}, \cdots, \hat{\varepsilon}_{Nt}]'$代替$\varepsilon_t$，计算样本$\hat{\boldsymbol{\Sigma}}$代替$\Sigma$，并使用样本协方差矩阵$\hat{\boldsymbol{\Sigma}}_f$代替$\boldsymbol{\Sigma}_f$。将$\hat{\boldsymbol{\Sigma}}$和$\hat{\boldsymbol{\Sigma}}_f$代入式（2.22）和式（2.23）就得到协方差矩阵的估计。进一步利用它们计算标准误即可进行检验。

尽管上述表达式看上去已经足够复杂了，但仍有两点需要简单说明。第一，在截面回归模型（2.18）中，作为解释变量的因子暴露$\hat{\boldsymbol{\beta}}$是从第一步时序回归中得来的，它们是估计值而非真实值。对于模型（2.18）来说，$\hat{\boldsymbol{\beta}}$被称为生成的回归变量（generated regressors）。因此在计算标准误时，应该对生成回归变量造成的误差进行修正。对于此，Shanken（1992）给出了解决该问题的修正方法（被称为Shanken修正），即在$\mathrm{cov}(\hat{\boldsymbol{\lambda}})$和$\mathrm{cov}(\hat{\boldsymbol{\alpha}})$的表达式中添加系数$(1+\boldsymbol{\lambda}'\boldsymbol{\Sigma}_f^{-1}\boldsymbol{\lambda})$：

$$\mathrm{cov}(\hat{\boldsymbol{\lambda}}) = \frac{1}{T}\left[\left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}'\boldsymbol{\Sigma}\hat{\boldsymbol{\beta}}\left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1}(1+\boldsymbol{\lambda}'\boldsymbol{\Sigma}_f^{-1}\boldsymbol{\lambda}) + \boldsymbol{\Sigma}_f\right] \tag{2.24}$$

$$\mathrm{cov}(\hat{\boldsymbol{\alpha}}) = \frac{1}{T}\left[\boldsymbol{I} - \hat{\boldsymbol{\beta}}\left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}'\right]\boldsymbol{\Sigma}\left[\boldsymbol{I} - \hat{\boldsymbol{\beta}}\left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}'\right]'(1+\boldsymbol{\lambda}'\boldsymbol{\Sigma}_f^{-1}\boldsymbol{\lambda}) \tag{2.25}$$

在实际应用中，使用$\hat{\boldsymbol{\lambda}}$代替$\boldsymbol{\lambda}$，$\hat{\boldsymbol{\Sigma}}_f$。第二，除Shanken修正外，截面OLS回归中存在的另外一个问题是，在截面上α_i存在相关性。这种相关性虽然不会影响OLS估计的性质，但是会使OLS计算的标准误存在巨大的误差，造成对标准误的低估。为解决这个问题，可以使用广义最小二乘（Generalized Least Squares，即GLS）代替OLS。

当使用GLS求解截面回归时，估计量$\hat{\boldsymbol{\lambda}}$和$\hat{\boldsymbol{\alpha}}$的表达式为（以下数学符号中加入了下标GLS以便和OLS表达式进行区分）：

$$\hat{\boldsymbol{\lambda}}_{\mathrm{GLS}} = \left(\hat{\boldsymbol{\beta}}'\boldsymbol{\Sigma}^{-1}\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}'\boldsymbol{\Sigma}^{-1}E_T[\boldsymbol{R}^e] \tag{2.26}$$

$$\hat{\boldsymbol{\alpha}}_{\mathrm{GLS}} = E_T[\boldsymbol{R}^e] - \hat{\boldsymbol{\beta}}\hat{\boldsymbol{\lambda}}_{\mathrm{GLS}} \tag{2.27}$$

当使用GLS并考虑Shanken修正后，$\mathrm{cov}(\hat{\boldsymbol{\lambda}}_{\mathrm{GLS}})$和$\mathrm{cov}(\hat{\boldsymbol{\alpha}}_{\mathrm{GLS}})$为：

WPS 仅供试用

$$\mathrm{cov}(\hat{\boldsymbol{\lambda}}_{\mathrm{GLS}}) = \frac{1}{T}\left[\left(\hat{\boldsymbol{\beta}}'\boldsymbol{\Sigma}^{-1}\hat{\boldsymbol{\beta}}\right)^{-1}\left(1+\boldsymbol{\lambda}_{\mathrm{GLS}}'\boldsymbol{\Sigma}_f^{-1}\boldsymbol{\lambda}_{\mathrm{GLS}}\right)+\boldsymbol{\Sigma}_f\right] \tag{2.28}$$

$$\mathrm{cov}(\hat{\boldsymbol{\alpha}}_{\mathrm{GLS}}) = \frac{1}{T}\left(\boldsymbol{\Sigma}-\hat{\boldsymbol{\beta}}\left(\hat{\boldsymbol{\beta}}'\boldsymbol{\Sigma}^{-1}\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}'\right)\left(1+\boldsymbol{\lambda}_{\mathrm{GLS}}'\boldsymbol{\Sigma}_f^{-1}\boldsymbol{\lambda}_{\mathrm{GLS}}\right) \tag{2.29}$$

在实际中，使用 $\hat{\boldsymbol{\Sigma}}$、$\hat{\boldsymbol{\Sigma}}_f$ 以及 $\hat{\boldsymbol{\lambda}}_{\mathrm{GLS}}$ 分别代替$\boldsymbol{\Sigma}$、$\boldsymbol{\Sigma}_f$以及$\boldsymbol{\lambda}_{\mathrm{GLS}}$就得到$\mathrm{cov}(\hat{\boldsymbol{\lambda}}_{\mathrm{GLS}})$和 $\mathrm{cov}(\hat{\boldsymbol{\alpha}}_{\mathrm{GLS}})$的估计。利用OLS或GLS得到的标准误，构建如下自由度为*N*-*K*的χ^2-检验统计量，检验全部*N*个定价误差是否联合为零：

$$\mathrm{OLS}: \hat{\boldsymbol{\alpha}}'\mathrm{cov}(\hat{\boldsymbol{\alpha}})^{-1}\hat{\boldsymbol{\alpha}} \sim \chi^2_{N-K} \tag{2.30}$$

$$\mathrm{GLS}: \hat{\boldsymbol{\alpha}}_{\mathrm{GLS}}'\mathrm{cov}(\hat{\boldsymbol{\alpha}}_{\mathrm{GLS}})^{-1}\hat{\boldsymbol{\alpha}}_{\mathrm{GLS}} \sim \chi^2_{N-K} \tag{2.31}$$

为了检验因子预期收益率，只需从$\mathrm{cov}(\hat{\boldsymbol{\lambda}})$ 或 $\mathrm{cov}(\hat{\boldsymbol{\lambda}}_{\mathrm{GLS}})$取出对角线上的元素并开方即可，它们就是*K*个因子收益率的标准误。对于每个因子，利用其预期收益率$\hat{\lambda}_i$和其标准误，计算出相应的*t*-统计量（自由度*T*-1）即可进行检验。以上就完成了截面回归检验。接下来简要总结一下。

（1）截面回归不要求因子的收益率时间序列已知，因此应用更加广泛。截面回归的第一步是通过时间序列回归得到每个资产*i*在因子上的暴露$\hat{\beta}_i$；第二步才是进行截面回归。因此这种方法又被称作两步回归估计（two-pass regression estimate）。

（2）在得到$\hat{\beta}_i$后，使用资产的时序平均收益率$E_T[R_i^e]$和$\hat{\beta}_i$进行截面OLS或GLS回归，估计出因子的期望收益率$\hat{\boldsymbol{\lambda}}$和资产的定价误差$\hat{\boldsymbol{\alpha}}$。

（3）由于$\hat{\beta}_i$是估计值，因此在计算$\hat{\boldsymbol{\lambda}}$和$\hat{\boldsymbol{\alpha}}$的标准误时可以进行Shanken修正。有了估计值和标准误，构建相应的χ^2-统计量和*t*-统计量来进行检验。

最后值得一提的是，截面回归既可以检验由风格因子构成的模型，也可以检验同时包括风格和宏观经济等不同类型的因子的模型。接下来的2.2.3节将比较时序回归和截面回归在分析风格因子上的异同。除此之外，本节使用的OLS和GLS估计中都假设了因子f_t和随机扰动ε_t之间相互独立，且各自在时序上满足独立同分布这个假设。当该假设不成立时，仍然可以使用广义矩估计来进行分析。此外，广义矩估计也可以方便地修正因因子暴露为估计值造成的误差。考虑到本书的侧重，以下不再对此进行展开介绍，感兴趣的读者请参考Cochrane（2005）。在学术界对因子模型的研究中，本节介绍的截面回归方法并不常见，但理解它可以更好地体会不同方法之间的差异，做到融会贯通。

2.2.3 时序回归vs截面回归

2.2.1和2.2.2两节分别介绍了时序回归和截面回归。有意思的是，对于风格因子这种可以通过排序法构建因子模拟投资组合并计算因子收益率时序的情况，既可以使用时序回归又可以使用截面回归来检验多因子模型。那么它们二者的区别是什么呢？

图2.6以单因子为例，直观地比较了二者的区别。时序回归仅在时序上对每个

WPS PDF编辑试用

资产进行回归，然后通过在时序上取均值来得到隐含的截面关系。这意味着图2.6中时序回归得到的$E[R_i^e]=\beta_i\lambda$必然经过（0, 0）和（1, λ）两点（其中λ是因子收益率的时序均值）。反观截面回归，它的第一步和时序回归完全一样，也是使用已有的因子收益率作为解释变量，得到资产的因子暴露的估计$\hat{\beta}_i$。然而在第二步，它没有采用“时序上取平均”，而是以$\hat{\beta}_i$为解释变量，以$E_T[R_i^e]$为被解释变量进行截面回归。以OLS为例，它以最小化所有资产定价误差$\hat{\alpha}_i$的平方和为目的。

在时序回归中，每个资产的定价误差的估计$\hat{\alpha}_i$来自独立的回归，即每个资产进行一次回归，一共进行N次，得到全部N个$\hat{\alpha}_i$；而在截面回归中，它第二步的截面回归以最小化所有N个$\hat{\alpha}_i$的平方和为目标，因此它同时利用了所有资产的数据。从某种意义上来说，这使得截面回归更加合理。对于时序回归，因子的平均收益率就是该因子模拟投资组合收益率在全部T期的均值；而对于截面回归来说，因子收益率通过OLS或GLS确定，它的取值将会和时序回归得到的因子收益率不同。这是二者最大的区别。

看到这里，有的读者朋友也许会问一个问题。对于风格因子，它们的因子模拟投资组合明明已经有了，因子收益率时间序列也有了，只需要通过在时序上取平均就可以得到因子预期收益率，而截面回归却进行了第二步，通过OLS或GLS得到因子预期收益率。这两种方法得到的因子收益率是不同的，那么它们之间有什么差异？到底哪个是更准确的呢？接下来从数学上回答这个问题。

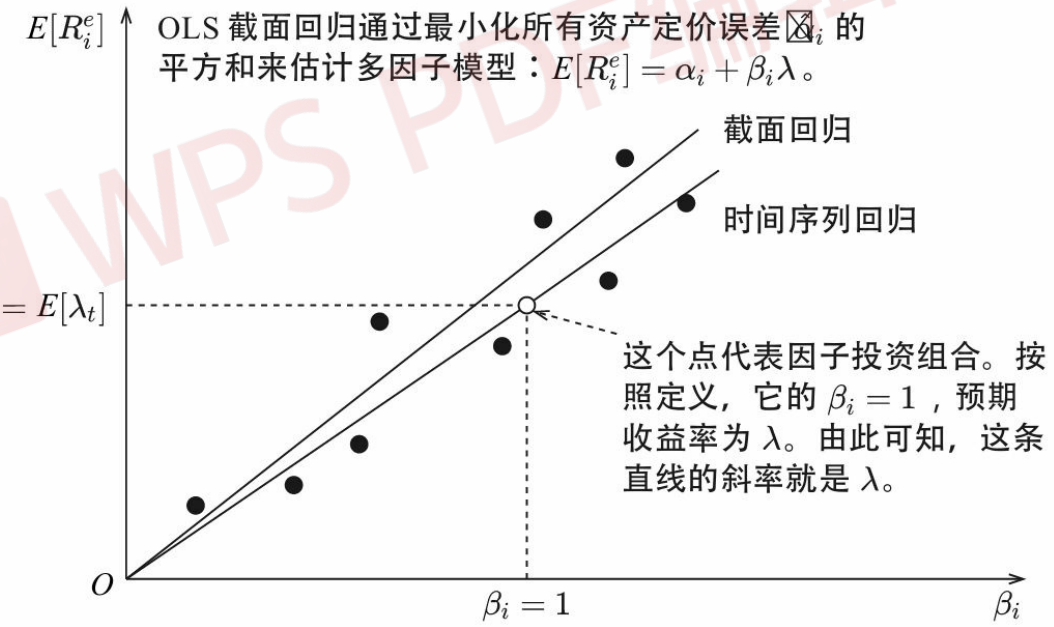


图2.6　时序回归vs截面回归

以OLS为例，由2.2.2节的叙述可知，因子预期收益率的估计量为：

$$\hat{\boldsymbol{\lambda}}=\left(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}}\right)^{-1}\hat{\boldsymbol{\beta}}'E_T[\boldsymbol{R}^e] \tag{2.32}$$

考察式（2.32）等号右侧$(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}})^{-1}\hat{\boldsymbol{\beta}}'$这部分的含义。由于$\hat{\boldsymbol{\beta}}$是$N\times K$因子暴露矩阵，因此前面这个表达式得到一个$K\times N$矩阵，它的每一行对应一个因子，每一列对应一个资产。它的第k行可以被视作因子k的一个投资组合，第k行、第i列的数值即为资产i在该投资组合中的权重。因此，这个$K\times N$矩阵$(\hat{\boldsymbol{\beta}}'\hat{\boldsymbol{\beta}})^{-1}\hat{\boldsymbol{\beta}}'$恰好构成了多因子模型中全部因子的$K$

个投资组合。接下来，将矩阵$(\hat{\beta}'\hat{\beta})^{-1}\hat{\beta}'$和因子暴露矩阵$\hat{\beta}$相乘，并经过简单的代数运算可得：

$$\left[\left(\hat{\beta}'\hat{\beta}\right)^{-1}\hat{\beta}'\right]\hat{\beta}=\left(\hat{\beta}'\hat{\beta}\right)^{-1}\left(\hat{\beta}'\hat{\beta}\right)=I \tag{2.33}$$

为了便于解释，令$\Omega\equiv(\hat{\beta}'\hat{\beta})^{-1}\hat{\beta}'$。式（2.33）展示出了矩阵Ω代表的因子投资组合的非常好的性质。对于任意一个因子k，它的投资组合中资产的权重是Ω的第k行。由于式（2.33）的结果等于单位矩阵I，它说明Ω的第k行和因子暴露矩阵$\hat{\beta}$的每一列相乘时，和任何$j\neq k$列的内积都是0，而和第k列的内积为1。令ω_{ki}表示Ω矩阵第k行、第i列的元素，$\hat{\beta}_{ij}$表示矩阵$\hat{\beta}$第i行、第j列的元素，则上述结果在数学上可以表达为：

$$\boldsymbol{\Omega}\text{ 的第 }k\text{ 行和 }\hat{\boldsymbol{\beta}}\text{ 的第 }j\text{ 列（}j\neq k\text{）内积：}\sum_{i=1}^{N}\omega_{ki}\hat{\beta}_{ij}=0 \tag{2.34}$$

$$\boldsymbol{\Omega}\text{ 的第 }k\text{ 行和 }\hat{\boldsymbol{\beta}}\text{ 的第 }k\text{ 列内积：}\sum_{i=1}^{N}\omega_{ki}\hat{\beta}_{ik}=1 \tag{2.35}$$

由Ω和$\hat{\beta}$的定义可知，前者中的ω_{ki}表示因子k的投资组合中资产i的权重，后者中的$\hat{\beta}_{ij}$表示资产i在因子j上的暴露。由此可知，$\sum_{i=1}^{N}\omega_{ki}\hat{\beta}_{ik}$则表示$N$个资产按权重$\omega_{ki}$在因子$j$上的暴露的加权平均，因为资产权重来自因子$k$的投资组合，因此这个加权平均也是因子$k$的投资组合对因子$j$的暴露。式（2.34）说明因子$k$的投资组合对任何其他因子$j$（$j\neq k$）的暴露均为零；而式（2.35）则表明因子$k$的投资组合对它自己的暴露是1。以上就是式（2.33）的含义。

从上面的论述可知，使用截面回归不仅求出了每个因子的预期收益率，而且还同时得到了每个因子的投资组合。该投资组合满足只对该因子有暴露，而对其他因子没有暴露这个优秀的性质。对于任意一个因子k，很显然截面回归得到的因子投资组合和排序法得到的因子投资组合是不同的，因此截面回归得到的因子预期收益率和时序回归的因子预期收益率[6]也自然不同。由于截面回归得到的Ω投资组合控制了在其他因子上的暴露，因此比起时序回归结果，通常认为截面回归得到的因子收益率能够更加客观地评价因子的风险溢价。这就是两种方法的差异。

WPS PDF 试用

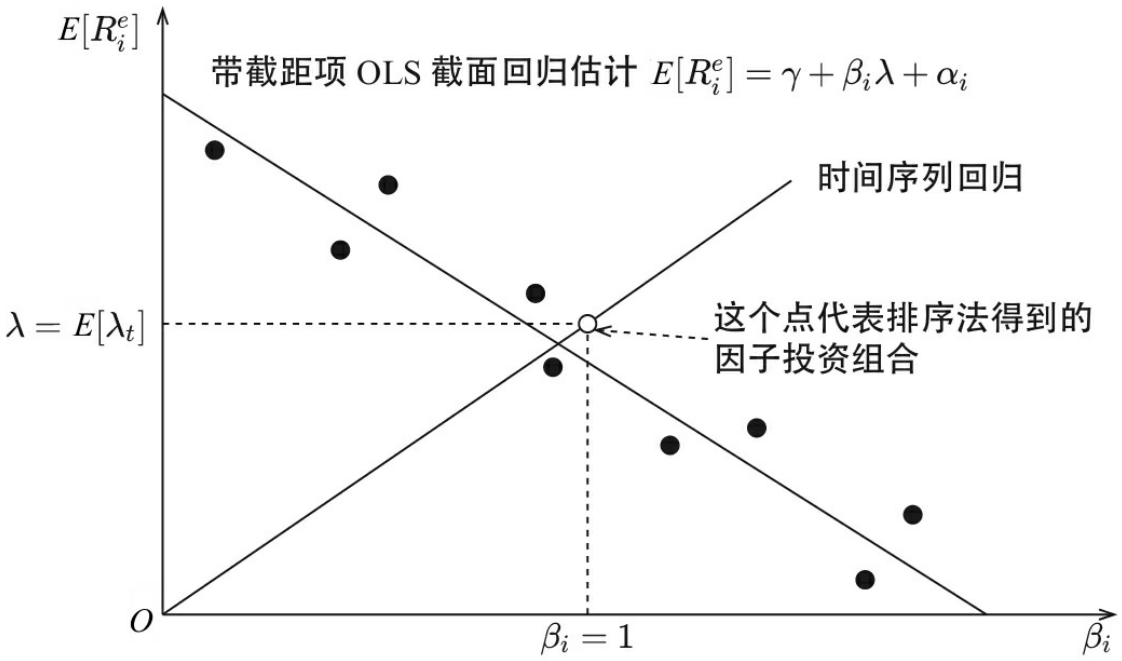


图2.7　同时用时序回归和截面回归检验模型

最后，时序回归和截面回归有时也被同时使用，以检验模型选择的因子是否有意义。考虑图2.7中假想的例子。假设对于某个因子，$E[R_i^e]$和β_i在截面上的关系如图2.7中黑色圆点表示，由时序回归定义可知，它的结果经过图中原点和代表因子投资组合的白色空心圆点。由于该直线的斜率为正，因此时序回归求出的因子预期收益率大于零。反观通过截面回归估计$E[R_i^e]=\gamma+\beta_i\lambda+\alpha_i$，由于这条直线会最小化所有$\hat{\alpha}_i$的平方和，因此会得到完全不同的结果：它的斜率为负，表明因子预期收益率小于零。两个模型的背离就反映出挑选的因子可能有问题，需要进一步分析。

2.2.4　Fama–MacBeth回归

1973年，Eugene Fama和James MacBeth在Fama and MacBeth（1973）一文中提出了一个两步回归方法（被称为Fama–MacBeth回归），该文的目的是检验CAPM。该方法非常巧妙地排除了随机扰动在截面上的相关性对标准误的影响，在业界被广泛使用。这篇文章也是计量经济学领域被引用最频繁的文章之一。

与2.2.2节类似，Fama–MacBeth回归的第一步也是通过N个时间序列回归得到每个资产i在全部因子上的暴露$\hat{\beta}_i$，这和截面回归的第一步相同。Fama–MacBeth回归和截面回归检验最大的差异体现在第二步截面回归上。截面回归检验使用$\hat{\beta}_i$和$E_T[R_i^e]$在截面上进行一次截面回归。Fama–MacBeth回归在每个时间点t，以t期的收益率R_{it}^e为因变量（注意：是t期的收益率，而非全部T期收益率的均值），以$\hat{\beta}_i$为自变量进行截面回归，因而一共进行了T次截面回归。这是Fama–MacBeth回归检验和截面回归检验最大的不同。在t期，资产超额收益和因子收益率在截面上的线性回归模型为：

$$R_{it}^e=\hat{\boldsymbol{\beta}}_i'\boldsymbol{\lambda}_t+\alpha_{it},\quad i=1,2,\cdots,N \tag{2.36}$$